

Régression et Sélection de variables — Application au jeu de données Bardet

2026-09-25

Ce devoir maison s'intéresse à la sélection de variables en régression, dans un contexte où le nombre de variables explicatives est grand devant le nombre d'observations. On utilisera pour cela le jeu de données **bardet**, disponible dans le package R **gglasso**, issu de l'étude de Scheetz et al. (2006) sur l'expression génique dans l'œil chez la souris.

Ce jeu de données contient :

- une variable réponse **bardet\$y** : le niveau d'expression du gène **TRIM32**, impliqué dans le syndrome de Bardet-Biedl ;
- une matrice de prédictors **bardet\$x**, construite à partir de l'expression de 20 gènes candidats, chacun représenté par 5 fonctions de base B-splines (afin de capturer une relation potentiellement non-linéaire entre chaque gène candidat et TRIM32), soit $p = 100$ colonnes organisées en 20 groupes de 5 colonnes consécutives, mesurées sur $n = 120$ individus.

On souhaite construire un modèle de **régression** permettant de prédire l'expression de TRIM32 à partir de ces 100 variables, tout en identifiant les gènes candidats qui lui sont réellement associés.

Votre rapport au format .pdf devra être généré à l'aide d'un document *R Markdown* ou *Jupyter Notebook*, dans lequel vous fournirez le code et les sorties permettant de répondre aux différentes questions.

Toutes vos réponses devront être soigneusement justifiées.

Question 1. Dans cette question, on s'intéresse à la pénalité elasticnet de type $\ell_1 + \ell_2$. Afin de comprendre l'impact de cette pénalité, en préambule, on s'intéresse au problème de régression suivant :

$$\hat{\beta} = \underset{\beta}{\operatorname{argmin}} \|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda_1 \|\beta\|_1 + \lambda_2 \|\beta\|_2^2$$

où $\mathbf{X}$ est le tableau de variables explicatives et $\mathbf{y}$ la variable à expliquer. On suppose dans cette question que $\mathbf{X}^\top \mathbf{X} = \mathbf{I}$. Montrer que :

$$\hat{\beta}_k = \frac{\max(0, |\hat{\beta}_k^{\text{OLS}}| - \frac{\lambda_1}{2})}{1 + \lambda_2} \cdot \operatorname{sign}(\hat{\beta}_k^{\text{OLS}})$$

où $\hat{\beta}_k^{\text{OLS}}$ est le k ème élément du vecteur de paramètres $\hat{\beta}^{\text{OLS}}$ obtenu par moindres carrés.

Question 2. Justifier le caractère parcimonieux qu'induit la pénalité $\ell_1 + \ell_2$.

Question 3. Charger le jeu de données **bardet** du package **gglasso** et construire un modèle de régression pénalisée $\ell_1 + \ell_2$ (elasticnet) pour prédire l'expression du gène TRIM32 (**bardet\$y**) à partir des 100 variables de **bardet\$x** (on pourra utiliser le package **glmnet** sous R, avec l'argument **family** = "gaussian").

Question 4. Comparer les résultats issus de la régression pénalisée $\ell_1 + \ell_2$ à ceux obtenus en pénalisant ℓ_1 ou ℓ_2 seul.

Remarque : Vous veillerez à optimiser les paramètres de tous ces modèles par cross-validation (fonction **cv.glmnet**).

Au-delà de la parcimonie individuelle : sélection de variables par groupes

Les pénalités ℓ_1 et $\ell_1 + \ell_2$ étudiées ci-dessus sélectionnent des variables *individuellement* : chaque coefficient β_k est annulé ou conservé indépendamment des autres. Or, dans `bardet`, les 100 colonnes de `bardet$x` ne sont pas 100 variables indépendantes : elles forment 20 groupes de 5 colonnes, chaque groupe correspondant aux coefficients de la base de splines d'un même gène candidat. Dans ce contexte, la question scientifique pertinente n'est pas "quelle fonction de base retenir ?" mais bien "quel gène retenir ?" : les 5 coefficients associés à un même gène doivent être sélectionnés ou annulés **ensemble**. C'est précisément ce que permet le **group LASSO**, contrairement au LASSO ou à l'elasticnet des questions précédentes, qui traitent chaque colonne indépendamment et peuvent ainsi sélectionner certaines bases d'un gène sans les autres.

Question 5. On rappelle que l'estimateur du group LASSO est défini, pour une matrice de prédicteurs partitionnée en G groupes $\beta = (\beta_1, \dots, \beta_G)$, par :

$$\hat{\beta} = \underset{\beta}{\operatorname{argmin}} \|\mathbf{y} - \mathbf{X}\beta\|^2 + \lambda \sum_{g=1}^G \sqrt{p_g} \|\beta_g\|_2$$

où β_g est le sous-vecteur des coefficients associés au groupe g , $\mathbf{X}_g$ le bloc de colonnes de $\mathbf{X}$ correspondant, et p_g la taille du groupe g .

On suppose, comme à la Question 1, que $\mathbf{X}^\top \mathbf{X} = \mathbf{I}_p$. Montrer que, dans ce cas, la solution se met sous la forme explicite :

$$\hat{\beta}_g = \left(1 - \frac{\lambda \sqrt{p_g}}{2 \|\hat{\beta}_g^{\text{OLS}}\|_2} \right)_+ \hat{\beta}_g^{\text{OLS}}$$

où $\hat{\beta}_g^{\text{OLS}}$ est le sous-vecteur du groupe g de l'estimateur des moindres carrés $\hat{\beta}^{\text{OLS}}$, et $(x)_+ = \max(0, x)$.

Indication : on pourra raisonner groupe par groupe, en montrant que sous l'hypothèse d'orthonormalité des groupes, le critère se réécrit comme une somme de G problèmes indépendants, chacun ne dépendant que de β_g .

Question 6.

- A partir de l'expression obtenue à la question 5, expliquer pourquoi cette pénalité induit une parcimonie *par groupe* (un groupe est soit entièrement nul, soit entièrement non-nul) plutôt qu'une parcimonie coefficient par coefficient, et en quoi ce comportement diffère de celui du LASSO ou de l'elasticnet des questions précédentes.
- Ajuster un modèle de group LASSO sur `bardet` (fonction `gglasso`, avec `loss = "ls"`) en utilisant l'indexation de groupes fournie dans la documentation du jeu de données (`group <- rep(1:20, each = 5)`). Sélectionner la valeur du paramètre de régularisation λ par validation croisée (fonction `cv.gglasso`) et reporter les gènes candidats retenus par le modèle optimal.
- Comparer les variables retenues par le group LASSO en b) à celles retenues par le LASSO classique de la question 4 (qui ignore la structure en groupes). Commentez les différences observées à la lumière de la structure en groupes du jeu de données.

Question 7. Comparer les performances prédictives des différents modèles ajustés (Ridge, LASSO, elasticnet, group LASSO) à l'aide d'une procédure de validation croisée, en reportant pour chacun une mesure d'erreur de prédiction adaptée à un problème de régression (par exemple l'erreur quadratique moyenne, MSE, ou le R^2 en validation croisée). Conclure sur l'intérêt respectif de chaque approche pour ce jeu de données.